راهنمای اجرای انسانی MGP-6 v3

راهنمای هماهنگ‌کننده — محرمانه

COORDINATOR ONLY

فقط برای هماهنگ‌کننده مطالعه — این فایل را کامل برای مشارکت‌کنندگان نفرستید.

نسخه ۳.۰ | همسو با پروتکل مستقل MGP-6 v3 | وضعیت: طراحی پیش‌ثبت‌شده و اجرانشده

> هدف این بسته، جداکردن واقعی طراحی کنترل‌گر، ساخت داده، برچسب‌گذاری، داوری و تحلیل است. اگر این جداسازی در عمل رعایت نشود، مجموعه حاصل «تأیید مستقل» محسوب نمی‌شود.

نسخه ۳.۰ • ۱۴۰۵/۰۴/۲۴

۱. هدف و مرز ادعا

MGP-6 v3 کیفیت تصمیم‌های حاکمیت حافظه را در طول یک مسیر گفتگو می‌سنجد: آیا حافظه فعلی باید حفظ شود (KEEP)، با حفظ تاریخچه جایگزین شود (SUPERSEDE) یا به‌علت کمبود شواهد دست‌نخورده بماند (ABSTAIN). واحد ارزیابی یک گذار حافظه درون trajectory است، نه یک جمله یا الگوی منفرد.

این راهنما فرایند جمع‌آوری و برچسب‌گذاری را استاندارد می‌کند. تا وقتی همه دروازه‌های انتشار پروتکل پاس نشده‌اند، نتیجه فقط تشخیصی است و نباید به‌عنوان برتری عمومی، ایمنی اثبات‌شده یا اعتبار بیرونی معرفی شود.

۲. اطلاعات اداری که باید قبل از دعوت تکمیل شوند

مورد	مقدار نهایی
نام پروژه/دانشگاه	[نام پروژه/دانشگاه]
مسئول پاسخ‌گو	[نام و راه ارتباطی مسئول]
نقش موردنیاز	[نویسنده / برچسب‌زن / داور]
حجم و مهلت	[تعداد آیتم، زمان تقریبی، مهلت]
پرداخت	[مبلغ، واحد پول، زمان و روش پرداخت]
محل امن تحویل	[سامانه یا مسیر امن]
مهلت انصراف/حذف	[تاریخ و روش درخواست]
مجوز بازتوزیع	[دامنه انتشار داده و برچسب‌ها]

تا زمانی که این خانه‌ها نهایی نشده‌اند، بسته را برای فرد واقعی ارسال نکنید.

۳. نقش‌ها و دیواره‌های دسترسی

نقش	مجاز به دیدن	غیرمجاز
مالک پروتکل/تیم کنترل‌گر	تعریف منجمد schema، task و dev	آیتم‌های gold، confirmation و test و داوری موردی
هماهنگ‌کننده داده	تخصیص‌ها، فرم رضایت، نسخه‌های تحویل، audit log	تغییر آیتم برای بهترشدن نتیجه یک سیستم
نویسنده داده	کارت شرط بی‌نام و راهنمای نویسنده	نام action، خروجی سیستم، توزیع کل برچسب‌ها و کد کنترل‌گر

نقش	مجاز به دیدن	غیرمجاز
برچسب‌زن A/B/C	آیتم کور، schema خروجی و راهنمای برچسب‌زن	قصد نویسنده، برچسب دیگران، خروجی سیستم و split محرمانه
داور چهارم	آیتم اختلاف و، در مرحله دوم، دلایل کور A/B/C	نام افراد، خروجی سیستم، gold مؤلف و رفتار کنترل‌گر
تحلیل‌گر	فایل‌های قفل‌شده و کد تحلیل منجمد	ویرایش پسینی آیتم، حذف مورد سخت یا جای‌گذاری نتیجه مفقود

یک نفر می‌تواند فقط یکی از نقش‌های «نویسنده»، «برچسب‌زن» یا «داور» را در confirmation test داشته باشد. هر تعارض منافع، مشارکت قبلی در طراحی کنترل‌گر یا مشاهده آیتم/خروجی باید پیش از تخصیص ثبت شود.

۴. فایل درست برای هر فرد

• نویسنده: 04_PARTICIPANT_CONSENT_FA_01 + WRITER_INSTRUCTIONS_FA + کارت‌های تخصیص خودش.

• هر برچسب‌زن: 04_PARTICIPANT_CONSENT_FA_02 + ANNOTATOR_INSTRUCTIONS_FA + کور خودش + batch.

• داور: 04_PARTICIPANT_CONSENT_FA_03 + ADJUDICATOR_INSTRUCTIONS_FA + بسته اختلاف پس از قفل برچسب‌ها.

• تیم کنترل‌گر: هیچ‌یک از آیتم‌ها یا برچسب‌های confirmation را پیش از ثبت همه predictionها دریافت نمی‌کند.

نام فایل‌ها، شیت‌ها یا لینک‌ها نباید writer، family، action یا split را لو بدهد. شناسه‌های خنثی مانند M3-C-000417 به‌کار ببرید.

۵. پیش‌نیاز آغاز اجرا

• ☐ تعریف action، taskها، schema، کد کنترل‌گر، promptها، thresholdها، cost matrixها، metricها و کد تحلیل freeze شده‌اند.

• ☐ hash، timestamp و محل آرشیو freeze ثبت شده است.

• ☐ قواعد exclusion و adjudication پیش از مشاهده برچسب‌ها نوشته شده‌اند.

• ☐ فهرست نقش‌ها و تعارض منافع تکمیل شده است.

• ☐ سه برچسب‌زن مستقل و یک داور واجدشرایط تعیین شده‌اند؛ حداقل یک برچسب‌زن non-expert آموزش‌دیده و خارج از تیم طراحی داده است.

• ☐ جبران خدمت، حجم کار، مهلت و فرایند انصراف روشن است.

- ☐ مسیر جدا و امن برای فرم‌های هویتی و فایل‌های پژوهشی ایجاد شده است.
- ☐ مثال‌های آموزشی از confirmation test جدا هستند و هیچ paraphrase یا skeleton مشترک ندارند.

۶. فرایند اجرایی گام‌به‌گام

گام ۱ — ثبت freeze و نقش‌ها

نسخه و SHA-256 همه artifacts منجمد را در audit log ثبت کنید. فهرست افراد را با شناسه مستعار نگه دارید و جدول اتصال نام واقعی به شناسه را خارج از مخزن پژوهشی و با دسترسی محدود ذخیره کنید.

گام ۲ — دعوت و رضایت آگاهانه

پیش از تحویل آیتم، توضیح نقش، زمان، پرداخت، ریسک‌ها، محرمانگی، امکان انصراف و دامنه انتشار را ارسال کنید. رضایت برای «مشارکت»، «انتشار برچسب/دلیل بی‌نام» و «استفاده از skeleton نیمه‌طبیعی» باید جداگانه ثبت شود؛ رد گزینه اختیاری نباید جبران خدمت را کاهش دهد.

گام ۳ — آموزش و calibration

برای هر نقش یک batch آموزشی مستقل از train/dev/test آماده کنید. برچسب‌زن‌ها ابتدا مستقل کار کنند و سپس فقط درباره manual گفت‌وگو شود. هر اصلاح manual باید قبل از batch اصلی نسخه‌گذاری و freeze شود. پیشنهاد پیش‌فرض برای صلاحیت برچسب‌زن: حداقل ۸۰٪ action صحیح در calibration، بدون خطای افشای داده شخصی و توانایی تکمیل evidence span و state/lineage؛ هر معیار متفاوت باید پیشاپیش ثبت شود.

گام ۴ — تخصیص ساخت داده

به نویسنده کارت شرط خنثی بدهید، نه نام action. کارت می‌تواند principal، نوع slot، تعداد turn، ساختار trajectory، منبع، دامنه زمانی، میزان اتکاپذیری و شرط minimal pair را تعیین کند. نویسنده نباید نتیجه مطلوب کنترل‌گر یا توزیع actionها را بداند.

گام ۵ — دریافت، بی‌نام‌سازی و کنترل فنی

هماهنگ‌کننده فقط کنترل‌های شکلی و حریم خصوصی را انجام می‌دهد: تعداد turn، وجود شناسه، نبود اطلاعات شخصی، خوانایی و تطابق با کارت. متن را برای نزدیک‌کردن به یک برچسب یا اصلاح خطای سیستم تغییر ندهید. هر بازگشت به نویسنده با دلیل و نسخه ثبت شود.

گام ۶ — split و ممیزی نشت

split باید هم‌زمان بر اساس trajectory family، source dialogue، writer و paraphrase family جدا باشد. هیچ‌یک از این خوشه‌ها نباید بین train، development و confirmation test مشترک باشد. ممیزی entity، embedding neighbour، n-gram، exact/normalized duplicate و author/source overlap پیش از unblinding اجرا و آرشیو شود.

گام ۷ — برچسب‌گذاری سه‌نفره و مستقل

هر گذار confirmation را هر سه برچسب‌زن می‌بینند. ترتیب آیتم‌ها برای هر نفر مستقل randomize شود. ارتباط درباره پاسخ آیتم‌ها، استفاده از LLM یا دیدن فایل دیگران ممنوع است. هر فایل پس از تحویل timestamp، read-only و hash شود.

گام ۸ — قفل و سنجش توافق

پس از تحویل هر سه نفر، raw labelها را بدون تصحیح حفظ کنید. توزیع action، توافق زوجی، Fleiss’ kappa، توافق per-class، اختلاف state/lineage و نرخ نیاز به داوری را با کد منجمد بسنجید. panel مدل‌ها، اگر وجود دارد، جداگانه و هرگز با عنوان human inter-annotator agreement گزارش نشود.

گام ۹ — داوری کور

فقط اختلاف‌ها به داور چهارم ارسال می‌شوند. داور ابتدا آیتم را بدون رأی‌های A/B/C برچسب می‌زند و judgment خود را قفل می‌کند؛ سپس دلایل کور سه نفر را می‌بیند و نتیجه نهایی را با استدلال ثبت می‌کند. نام افراد، رأی اکثریت و خروجی سیستم‌ها نمایش داده نشود.

گام ۱۰ — unblinding، prediction و انتشار

gold confirmation تا زمانی که هر سیستم فایل prediction کامل و immutable نداده پنهان می‌ماند. exclusion پس از دیدن عملکرد سیستم ممنوع است. پس از تکمیل، hashها، نقش‌ها، تغییرات، نمونه‌های disputed، روش پرداخت در سطح تجمیعی و محدودیت‌ها همراه dataset card منتشر شوند؛ فرم‌های هویتی هرگز منتشر نشوند.

۷. الزامات نمونه‌گیری و کیفیت داده

- هر relation/family باید هر سه action را با تعداد معنادار داشته باشد؛ هیچ type یا metadata عمومی نباید action را تعیین کند.
- minimal pairها فقط یک premise شواهدی را تغییر دهند و wording/record type تا حد ممکن ثابت بماند.
- دست‌کم نیمی از test شامل trajectoryهای ۵، ۱۰ یا ۲۰ turn با چند slot و delayed evidence باشد.
- دست‌کم یک‌سوم test نیمه‌طبیعی و برگرفته از skeletonهای بی‌نام و دارای رضایت یا توزیع منبع مستقل باشد.
- الگوهای slot update، branching، repeated confirmation، A→B→A، A→B→C و delayed retraction پوشش داده شوند.
- retraction، correction، contradiction، elaboration، duplicate و uncertain conflict پوشش داده شوند.
- weak inference، delegated source، first-party verified/unverified و conflicting sources پوشش داده شوند.

- ambiguous time و current، expired، retrospective correction، future-scoped پوشش داده شوند.
- derived و stable profile، temporary state، preference، plan/commitment summary پوشش داده شوند.

پیش از پذیرش مجموعه، probeهای majority، type-only، conflict-only، public-metadata را اجرا کنید. اگر هر probe غیرمعنایی بیش از ۰٫۱۰ accuracy مطلق بالاتر از majority باشد یا bag-of-words logistic، shallow tree و lexical decision list یک field عمومی از ۰٫۵۰ بیشتر شود، مجموعه رد و بازتولید می‌شود؛ normalized information gain را پس از دیدن threshold نتیجه تغییر ندهید.

۸. حریم خصوصی و داده نیمه‌طبیعی

داده خام گفت‌وگوی واقعی را داخل بسته کاری قرار ندهید. نویسنده فقط skeleton بی‌نام و مجاز را بازنویسی می‌کند. نام، نام کاربری، ایمیل، شماره، نشانی، شناسه دستگاه، مکان دقیق، مؤسسه کوچک، بیماری، وضعیت مالی، محتوای جنسی، باور سیاسی/مذهبی و هر ترکیب قابل‌شناسایی حذف یا مصنوعی شود.

اگر اطلاعات شخصی مشاهده شد: کار را متوقف کنید، آیتم را در پاسخ یا چت کپی نکنید، فقط شناسه آیتم را به مسئول حریم خصوصی گزارش دهید و فایل را طبق رویه امن قرنطینه کنید.

۹. قواعد تغییر، رد و exclusion

- رد فنی قبل از annotation مجاز است: خرابی فایل، PII، فقدان turn ضروری یا نقض روشن کارت شرط.
- سخت‌بودن، اختلاف انسانی یا خطای یک سیستم دلیل حذف نیست.
- پس از قفل predictionها، آیتم حذف نمی‌شود مگر طبق قانون ازپیش‌ثبت‌شده؛ نتیجه با و بدون آیتم معیوب به‌عنوان sensitivity گزارش می‌شود.
- هیچ متن یا goldی silent edit نمی‌شود. هر تغییر باید `new_hash`، `old_hash`، دلیل، مسئول، زمان و اثر بر split را داشته باشد.
- داده مفقود، timeout یا خروجی ناقص label جعلی نمی‌گیرد و جداگانه به‌عنوان system failure گزارش می‌شود.

۱۰. پیام آماده دعوت

سلام. برای پروژه پژوهشی [نام پروژه/دانشگاه] از شما دعوت می‌کنیم در نقش [نقش] در ارزیابی تصمیم‌های حاکمیت حافظه گفتگو مشارکت کنید. کار شامل [شرح کوتاه و تعداد آیتم] است و حدود [زمان] طول می‌کشد. جبران خدمت [مبلغ و روش پرداخت] است و پرداخت به هم‌نظر بودن با پژوهشگر وابسته نیست. مشارکت داوطلبانه است؛ اطلاعات هویتی در داده پژوهشی منتشر نمی‌شود و جزئیات انصراف، محرمانگی و بازتوزیع در رضایت‌نامه آمده است. در صورت تمایل، لطفاً تا [مهلت] از طریق [راه ارتباطی] پاسخ دهید.

۱۱. بسته تحویل و نام‌گذاری پیشنهادی

artifact	نمونه نام	وضعیت انتشار
role registry	private_role_registry_v1.csv	محرمانه
writer draft	writer_W07_batch_03_v2.csv	محدود
blind batch	blind_A_batch_04.csv	محدود
raw annotation	labels_A_locked.csv	پس از رضایت، بی‌نام
disagreement packet	adjudication_round_01_blind.csv	محدود
adjudicated gold	confirmation_gold_v1.jsonl	تا unblinding محرمانه
audit log	v3_audit_log.csv	قابل انتشار پس از پاک‌سازی

۱۲. دروازه نهایی تحویل به تحلیل‌گر

- ☐ همه نقش‌ها، رضایت‌ها و تعارض منافع ثبت شده‌اند.
- ☐ هیچ فردی دو نقش ناسازگار ندارد.
- ☐ سه label مستقل برای همه آیتم‌های confirmation موجود است.
- ☐ raw labelها، hashها و timestampها حفظ شده‌اند.
- ☐ همه اختلاف‌ها طبق rule منجمد داوری شده‌اند.
- ☐ split/shortcut/privacy auditها پاس و آرشیو شده‌اند.
- ☐ همه predictionهای ثبت‌شده کامل و immutable هستند.
- ☐ هیچ exclusion پس از مشاهده عملکرد ایجاد نشده است.
- ☐ dataset card محدودیت‌ها، جبران خدمت، consent و خطاهای پروتکل را صریح گزارش می‌کند.

اگر هر مورد پاس نشد، وضعیت نتیجه «diagnostic/incomplete» باقی می‌ماند و شواهد مفقود حدس زده یا جای‌گذاری نمی‌شوند.