جلسهٔ دفاع پایان‌نامهٔ کارشناسی ارشد

حاکمیت حافظهٔ بلندمدت پیش از بازیابی

نگه‌داری · جایگزینی · خودداری برای حافظهٔ نوع‌دار، منشأدار و دارای تبار

علی محمدی · سامانهٔ حاکمیت حافظهٔ KSA · ۲۰۲۶

حافظهٔ بلندمدت یک حالت تغییرپذیر است، نه یک مخزن سند

هر نوشتن، آنچه عامل بعداً «درست» می‌پندارد تغییر می‌دهد.

امتیاز بازیابی نمی‌تواند سازگاری، جایگزینی، یا ناایمن‌بودن شواهد برای ثبت را تعیین کند.

خط لولهٔ صرفاً بازیابی‌محور، تصمیم نوشتن را ضمنی می‌گذارد

حافظهٔ بازیابی‌محور

ثبت ← رتبه‌بندی ← پاسخ

فقط یافتن مورد مرتبط را بهینه می‌کند؛ تعارض، عدم‌قطعیت و تاریخچه به اثر جانبی تبدیل می‌شوند.

حافظهٔ تحت حاکمیت

بررسی ← تصمیم ← گذار

کنش نوشتن را صریح می‌کند، تاریخچهٔ جایگزین‌شده را حفظ می‌کند و چرایی تغییر حالت را ثبت می‌کند.

شکاف پژوهش، نبود یک مرز نوشتنِ صریح و قابل‌اندازه‌گیری است

تاریخچه

بازنویسی ادعای قدیمی را پنهان می‌کند و حافظهٔ افزایشی می‌تواند تعارض‌ها را هم‌زمان فعال نگه دارد.

ارزیابی

دقت پاسخ مشخص نمی‌کند خطا از نوشتن، گذار حالت، بازیابی، یا تولید پاسخ آمده است.

کنش

سامانه‌ها ADD/UPDATE/NOOP دارند، اما درستیِ کنش را هنگام تعارض مستقیماً نمی‌سنجند.

عدم‌قطعیت

NOOP معمولاً یعنی «اطلاعات تازه نیست»، نه «شواهد برای ثبت ایمن نیست».

سیاست، سه کنش و معنای دقیق گذار حالت را تثبیت می‌کند

واژگان کنش در کد ثابت است؛ مدل پیشنهاد می‌دهد اما گذار چهارمی نمی‌سازد.

KEEP نگه‌داری

ادعای سازگار را فعال ثبت می‌کند و رکوردهای بدون تعارض را فعال نگه می‌دارد.

SUPERSEDE جایگزینی

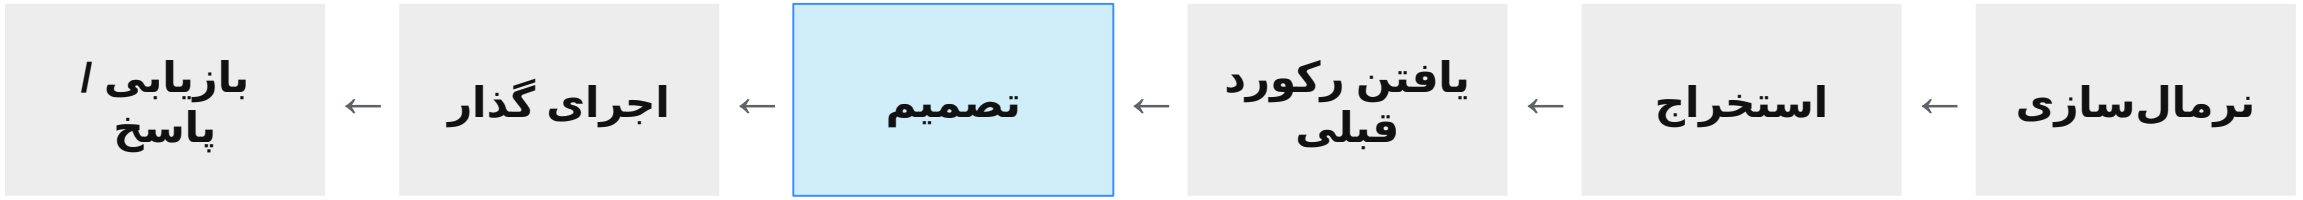
ادعای جدید را فعال، ادعای متعارض قبلی را غیرفعال و پیوند تبار را ثبت می‌کند.

ABSTAIN خودداری

حافظه را تغییر نمی‌دهد و تعارض یا ابهام را برای بازبینی ثبت می‌کند.

منبع: فصل‌های ۳ و ۴ پایان‌نامه؛ src/ksa/memory/operations.py

پیشنهاد مدل را درون یک مرز حاکمیت قطعی قرار می‌دهد KSA



شواهد نوع‌دار + رابطه‌ها ← سیاست ثابت ← گذار اتمی و قابل‌ممیزی

منبع: src/ksa/pipeline/orchestrator.py و شکل معماری مخزن

کنترل‌گر تفسیرپذیر دو امتیاز و یک قاعدهٔ ترتیبی دارد

```
if S_abs > θ_abs(τ):
    ABSTAIN
elif S_sup > θ_sup(τ) and max(0, −r) > 0:
    SUPERSEDE
else:
    KEEP
```

پنج ویژگی خوانا

رابطه، سازگاری نوع، منشأ، اطمینان و سیگنال تعارض.

شاخهٔ توضیح‌پذیر

امتیازها، آستانه‌ها و شاخهٔ انتخاب‌شده ثبت می‌شوند.

منبع: src/ksa/controller/policy.py و scoring.py

تبار، بازنگری را قابل‌برگشت و قابل‌ممیزی می‌کند



رکورد قبلی فعال

ادعای جاری به‌عنوان حالت فعلی بازیابی می‌شود.

شواهد متعارض تازه

سیاست فقط با شناسایی رکورد هدف، جایگزینی را می‌پذیرد.

گذار پیوندخورده

رکورد جدید فعال و رکورد قبلی غیرفعال اما قابل‌پرس‌وجو است.

منبع: عملیات حافظه و معیار سلامت تبار

تصمیم نوشتن را در شش نوع تعارض جدا می‌کند MGP-6

آزمون تشخیصی مصنوعیِ طراحی‌شده توسط پژوهشگر؛ ۶۰ آموزش، ۳۰ توسعه، ۹۰ آزمون نگه‌داشته‌شده.

180

سناریو با شناسهٔ پایدار و کنش طلایی

6

نوع سناریو برای به‌روزرسانی، تعارض و ابهام

90/66/24

توزیع جایگزینی / خودداری / نگه‌داری

منبع: گزارش‌های نهایی MGP-6 v2؛ n=180 مگر آنکه ذکر شود

پروتکل، وضعیت نتیجه و لایهٔ ارزیابی را از هم جدا می‌کند

لایهٔ پاسخ

مقاومت در برابر پیش‌فرض، کاربرد ضمنی و پرسش‌پاسخ پایین‌دستی.

دروازهٔ ادعا

وارد جدول اصلی final_candidate فقط اجرای کامل و معتبر می‌شود.

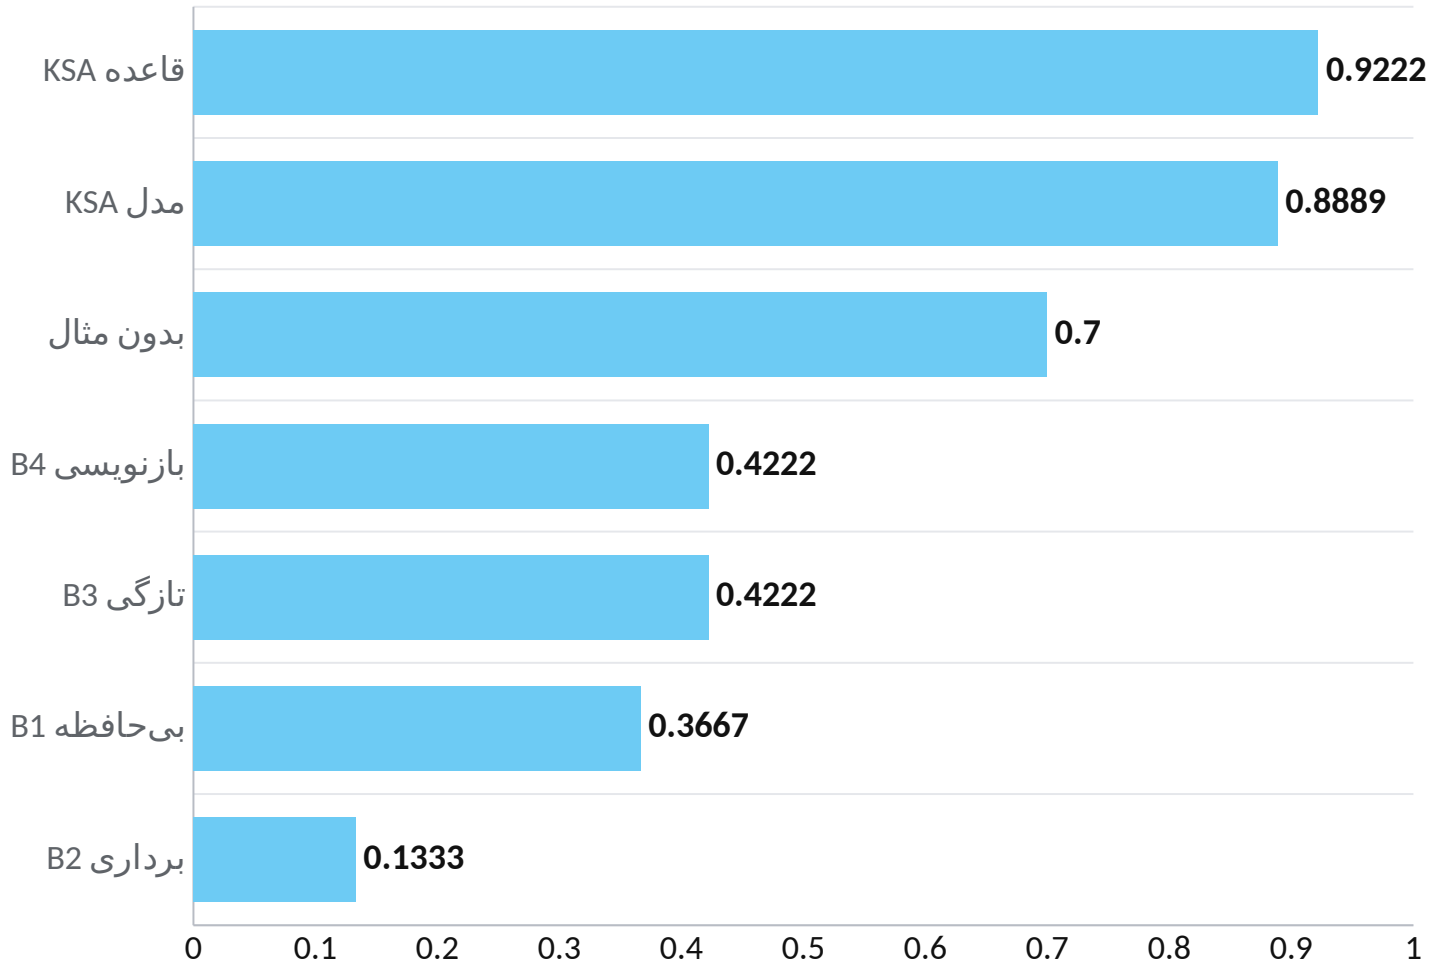
لایهٔ تصمیم

کلان، ماتریس خطا و ثبت نامعتبر F1 ،دقت کنش.

لایهٔ حالت

سلامت تبار، بازیابی رکورد منسوخ و قیدهای گذار.

را دارد MGP-6 حاکمیت ساخت‌یافته بالاترین دقت تصمیم



واحد درصد +۱۸٫۹

قاعده‌ای در برابر تصمیم بدون KSA ساختار. p اصلاح‌شدهٔ Holm برابر 1.6×10^{-5} است.

تفاوت کنترل‌گر قاعده‌ای و مدل‌محور از نظر دقت معنادار نیست (p=0.286).

منبع: گزارش‌های MGP-6 و تحلیل آماری جفتی n=180

خطاهای باقی‌ماندهٔ کنترل‌گر قاعده‌ای محافظه‌کارانه‌اند

ماتریس کامل: نگه‌داری ۲۴/۲۴؛ خودداری ۶۶/۶۶؛ جایگزینی ۷۶/۹۰.

0.9222

کلان F1 0.9399 دقت کنش؛

0.0

نرخ ثبت نامعتبر روی موارد خودداری

14

همهٔ خطاها جایگزینی ← خودداری

منبع: گزارش نهایی کنترل‌گر MGP-6

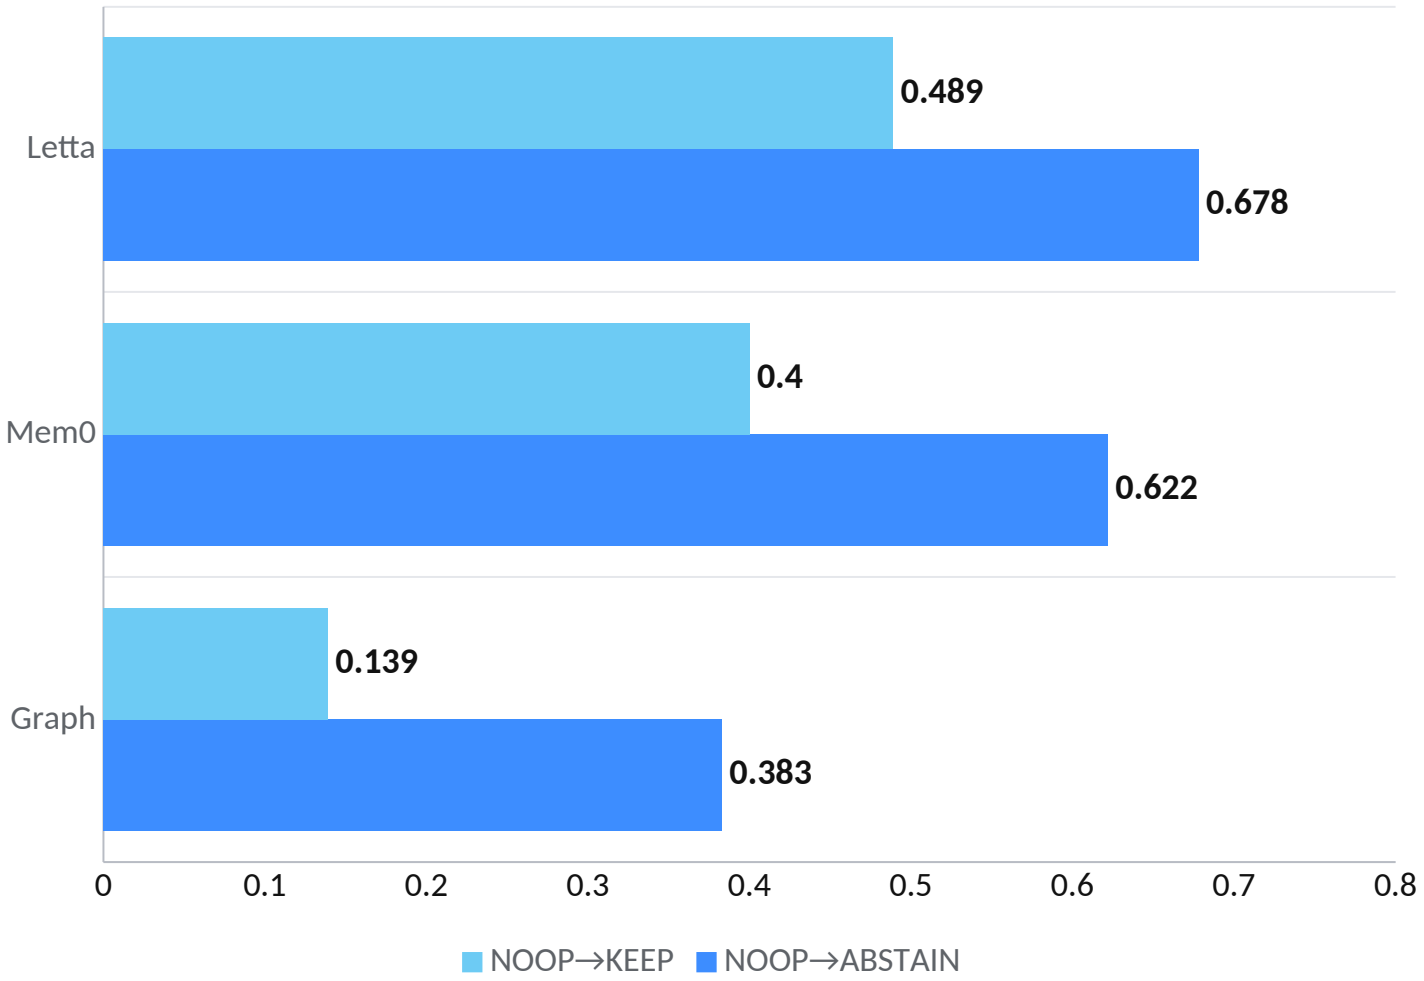
حذف هر مؤلفه، امضای خطای متفاوتی ایجاد می‌کند

.دقت کنش به‌تنهایی افت تبار را نمی‌بیند؛ معیارهای ایمنی سازوکارهای متفاوت را آشکار می‌کنند

سامانه	دقت	کلان F1	امضای اندازه‌گیری‌شده
کامل KSA	0.9222	0.9399	ثبت نامعتبر 0.0
بدون خودداری	0.5556	0.4278	ثبت نامعتبر ← 1.0
بدون منشأ	0.7000	0.7428	ثبت نامعتبر ← 0.606
بدون نوع	0.7889	0.5680	نگه‌داری ← F1 0.0
بدون تبار	0.9222	—	تبار 0.8556 ← 0.3689

منبع: اجرای کامل حذف مؤلفه‌های MGP-6

وابسته است NOOP امتیاز سامانه‌های بیرونی به نگاشت



کران وابسته به نگاشت

این رابط‌ها معنای کنش را KSA مستقیماً ارائه نمی‌کنند. هر دو نگاشت باید گزارش شود.

با امتیاز 0.144 فقط تشخیصی MemOS است، چون جایگزینی در رابط مشاهده‌پذیر نیست.

منبع: گزارش‌های رابط سامانه‌های بیرونی؛ دفتر نتایج v1.1

شواهد برچسب‌گذاری قوی است، اما فقط یک برچسب‌زن مستقل دارد

فقط بخش آزمون؛ برچسب خام تا دریافت رضایت بازتوزیع در انتشار عمومی قرار نمی‌گیرد.

89/90

توافق مستقل روی کنش

κ=0.981

کاپای کوهن؛ فاصلهٔ ۹۵٪: 0.940 تا 1.0

4 LLMs

پنل ممیزی جداگانه؛ توافق انسانی نیست

منبع: خلاصهٔ توافق انسانی و ممیزی چهارمدلی

نتیجهٔ نهایی نداریم و عدد ۷۷٫۲٪ رد می‌شود LongMemEval برای

است. externally_pending ،و پیش از استنتاج HTTP 403 اجرای همگن نهایی 1.1 پس از

96/154

تعداد درست خام در موارد مشاهده‌شده

53.3–67.8%

کران بدبینانه/خوش‌بینانهٔ خام روی ۱۸۰

55.6–70.0%

کران با حفظ چهار بازداوری Codex/GPT-5

ساخت تاریخی ۱۳۹/۱۸۰ = ۷۷٫۲٪ فقط شکست‌های قبلی را بازپخش و است، نه نتیجه failure_replay_only موفقیت‌ها را حمل کرده است؛.

منبع: حقیقت علمی و بازسازی اجراها LongMemEval

ترجیحات تک‌جلسه‌ای دشوارترین توانایی پایین‌دستی است

متفاوت بود؛ بنابراین ۰/۱۹ اثر خالص مدل پاسخ را جدا نمی‌کند v7 پرامپت بازپخش با.

8/29

درست مشاهده‌شده در موارد حل‌شده

≤9/30

بیشترین مقدار ممکن برای کل توانایی

12/19

خطاهای منسوب به رتبه‌بندی بازیابی

منبع: طبقه‌بندی خطای SSP و دفتر نتایج v1.1

تحلیل خطا، شکست ایمنی را از شکست پوشش جدا می‌کند

حذف تبار

دقت تصمیم ثابت است ولی قابلیت ممیزی به‌شدت افت می‌کند.

LongMemEval در SSP

خطاها در رتبه‌بندی، ساخت زمینه، انتساب و تولید پاسخ محلی‌سازی می‌شوند.

قاعده‌ای KSA

بازیابی محافظه‌کارانهٔ جایگزینی: هر خطای باقی‌مانده خودداری می‌کند.

تصمیم بدون ساختار

در ۶۰٫۶٪ مواردِ طلاییِ خودداری، ثبت نامعتبر انجام می‌دهد.

منبع: گزارش طبقه‌بندی خطا و تحلیل SSP

نتیجه‌گیری‌ها عمداً محدود نگه داشته شده‌اند

اعتبار رابط

مقایسهٔ بیرونی کران وابسته به رابط و نگاشت است.

شواهد پایین‌دستی

نهایی نداریم و معیارهای ایمنی به اعتبارسنجی LongMemEval بیرونی نیاز دارند.

آزمون مصنوعی

طراحی پژوهشگر، کوچک و غیرنمایندهٔ جمعیت واقعی MGP-6 است.

برچسب‌گذاری

یک برچسب‌زن مستقل؛ هویت و استقلال بر گواهی نویسنده متکی است.

منبع: تهدیدهای اعتبار و سند محدودیت‌ها

ابتدا نوشتن را حاکمیت کنید؛ سپس حالت و پاسخ را بسنجید

01

شواهد پایین‌دستی هنوز کامل نیست؛ اجرای همگن اقدام بیرونی بعدی است.

02

امضاهای متفاوت ایمنی و تبار MGP-6 را آشکار می‌کند که دقت پاسخ پنهان می‌سازد.

03

مرز ثابت نگه‌داری / جایگزینی / خودداری، گذار حافظه را صریح و قابل‌ممیزی می‌کند.

پشتیبان — تعریف رسمی تصمیم و شکست

$$d_t = \pi(c_t, r_t, M_t) \in \{KEEP, SUPERSEDE, ABSTAIN\}$$

$$\text{Invalid commit} = \Pr(\hat{y} \in \{K,S\} \mid y=A)$$
$$\text{Missed supersession} = \Pr(\hat{y} \neq S \mid y=S)$$
$$\text{Lineage integrity} = \text{valid links} / \text{expected links}$$

ایمنی ثبت

در کنش طلاییِ خودداری، هیچ تغییر حالتی مجاز نیست.

درستی حالت

برچسب درست کافی نیست اگر گذار یا تبار خراب باشد.

منبع: پیوست C پایان‌نامه و تعریف معیارهای نهایی

پشتیبان — سازوکار مبناها و قابلیت‌های قابل‌بیان

سامانه	سازوکار	خودداری؟	تبار؟
B1	بدون حافظهٔ پایدار	خیر	خیر
B2	بازیابی برداری تخت	خیر	خیر
B3	هرس تازگی	خیر	خیر
B4	بازنویسی ساده	خیر	خیر
قاعده KSA	سیاست پنج‌ویژگی	بله	بله
مدل KSA	در همان چارچوب Qwen تصمیم	بله	بله

منبع: فصل ۵ پایان‌نامه و رابط‌های مبنا

پشتیبان — آزمون‌های آماری و دامنهٔ استنباط

کنتراست	اختلاف ریسک	هولم p	تفسیر
قاعده در برابر صفرنمونه	+0.2222	1.6×10^{-5}	بهبود پشتیبانی‌شده
مدل KSA قاعده در برابر	+0.0333	0.286	غیرمعنادار
B4 قاعده در برابر	+0.5000	<0.001	کنتراست تشخیصی
LongMemEval	—	—	بدون آزمون؛ طراحی پاک نداریم

منبع: گزارش تحلیل آماری؛ n=180 جفتی

پشتیبان — توافق برچسب‌گذاری و یک مورد مرزی

.تنها اختلاف: تعارض ضمنی با برچسب طلایی جایگزینی و برچسب مستقل خودداری

0.9889

توافق خام در ۹۰ مورد آزمون

0.9815

چهار مدل؛ ممیزی جدا Fleiss کاپای

±1.1%

حساسیت بخش آزمون به یک مورد

منبع: بستهٔ ممیزی برچسب‌گذاری و پیوست D

پشتیبان — کنترل نشت داده و آزادی عمل پژوهشگر

وضعیت اجرا

بازپخش، ناقص، نامعتبر و تشخیصی وارد جدول نهایی نمی‌شوند.

تغییر پسینی

بازداوری، انتخاب شکست‌ها، تغییر مدل و تکمیل مکمل صریح ثبت می‌شوند.

شناسهٔ ثابت

پیش‌بینی با شناسه هم‌تراز و پوشش و تکرار بررسی می‌شود.

افشای تقسیم

نتیجهٔ ۱۸۰ شامل آموزش و توسعه است؛ آزمون ۹۰تایی جدا گزارش می‌شود.

منبع: ممیزی نشت داده و آزادی عمل پژوهشگر

فقط تشخیصی است LongMemEval پشتیبان — چرا شواهد

v7

مورد آلوده ۱۸۰

خطای 402؛ ۳۸۸ جایگزین ۳۱۶ خالی؛ تشدید بی‌اثر.

بازپخش

شکست انتخاب‌شده ۷۰

درست با پرامپت و داور ۲۵/۷۰ متفاوت.

تکمیل

موفقیت مکمل ۱۱۰

کامل؛ ۷۱ درست و ۱۳ پسرفت ۸۴.

منبع: حقیقت علمی LongMemEval و دفتر مقایسهٔ اجراها

پشتیبان — نگاشت کنش سامانه‌های بیرونی

رابط	NOOP→ABSTAIN	NOOP→KEEP	محدودیت ساختاری
Letta	0.678	0.489	KSA فاقد معنای خودداری
Mem0	0.622	0.400	یعنی بدون به‌روزرسانی NOOP
Graphiti	0.383	0.139	ابطال گراف برابر کنش طلایی نیست
MemOS	0.144	—	جایگزینی نامشهود؛ فقط کران

پشتیبان — نزدیک‌ترین کارها ادعای نوآوری را محدود می‌کنند

کار نزدیک	ایدهٔ مشترک	تفاوت با ترکیب ارزیابی‌شدهٔ KSA
TOKI	انتظار تأیید و ردیف ممیزی	قرارداد پایگاه‌داده؛ بدون ارزیابی سیاست LLM
Memory-R1	کنش‌های گسستهٔ نوشتن	غیرشفاف؛ پاداش سطح پاسخ RL سیاست
MemGuard	حافظهٔ نوع‌دار	بدون سیاست سه‌گانه و آزمون تبار
STALE	حل حالت و مقاومت پیش‌فرض	معیار خواندن، نه گذار نوشتن
Graphiti/Zep	ابطال زمانی	ابطال به‌عنوان کنش حاکمیتی سنجیده نشده

منبع: تحلیل نزدیک‌ترین همسایه‌ها و ماتریس نوآوری

پشتیبان — خطرهای اخلاقی و استقرار

مرز خودکارسازی

.نتایج پژوهش، تغییر خودکار نامحدود حافظه را توجیه نمی‌کند

کاهش خطر

تبار افزایشی، کنترل دسترسی، تأیید دوگانه، بازبینی و سیاست نگه‌داری.

سوءاستفاده از بازنگری

.جایگزینی می‌تواند برای بازنویسی سابقه یا جعل منشأ به‌کار رود

خطر نگه‌داری

حفظ تاریخچه ریسک حریم خصوصی، استخراج و استنباط عضویت را افزایش می‌دهد.

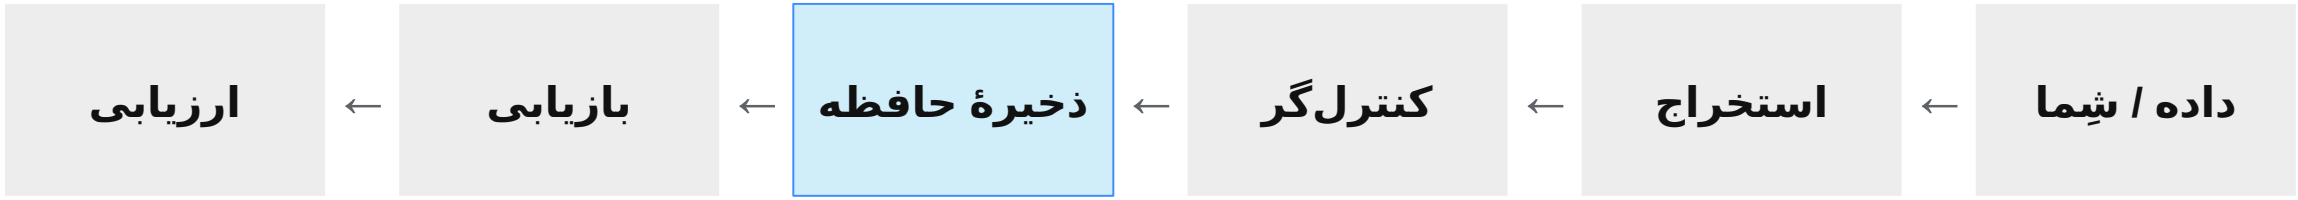
منبع: فصل ۹ پایان‌نامه و بحث NIST AI RMF

MGP-6 پشتیبان — نتایج کامل تکمیلی

سامانه	دقت	کلان F1	ثبت نامعتبر	مقاومت پیش‌فرض
قاعده KSA	0.9222	0.9399	0.0000	1.0000
مدل KSA	0.8889	0.8913	0.0758	0.0889
صفرنمونه	0.7000	0.6657	0.6061	—
بازنویسی B4	0.4222	0.2203	1.0000	—
شش‌نمونه	0.7833	0.7692	—	ناقص 174/180

منبع: گزارش‌های نهایی MGP-6 v2

پشتیبان — معماری کد با لایه‌های ارزیابی هم‌راستاست



آزمون‌ها قیدها، بازیابی پس از خطا، ادغام، منشأ و امتیازدهی را پوشش می‌دهند MGP قطعی

منبع: src/ksa؛ scripts/evaluation؛ testsکد به رفتار ردیابی ؛